

전처리 보고서

— EDA 최종본에서 도출한 설계·구현·실행 결과

항공엔진 잔여수명(RUL) 예측 기반 정비 스케줄링 최적화 프로젝트

July 13, 2026

Abstract

본 보고서는 EDA 최종본(eda_report.tex)에서 도출한 전처리 설계를 노트북(notebooks/02_preprocessing.ipynb)으로 구현·실행한 결과를 기록한다. 설계 단계에서 예측한 모든 수치가 실측과 일치했고, 검증 assertion **V1-V15**가 전부 통과했다. 가장 중요한 개선은 조건 지시 센서(s1, s5, s18, s19) 제외와 z-clip(± 10)으로 분산 **0**인 죽은 특징이 완전히 사라진 것이다(직전 구현 FD004 28개/16.4% → **0**개). Tabular 경로(LightGBM)와 Sequence 경로(LSTM)의 FD별 산출물에 더해, **통합 모델용** 조립까지 완료하였다: 합집합 17센서로 정렬한 통합 tabular(160,359행, engine_id 포함)와 통합 시퀀스 텐서($F = 27$)를 생성하고, NaN 패턴·engine 유일성·zero-fill을 V13-V15로 검증하였다. 나아가 통합 산출물의 무결성을 **9종 외부 교차 대조(U1-U9)**로, 소비 가능성을 **LightGBM 실학습 smoke test**(valid RMSE 15.28, FD001 14.66 — 기준선 근처, 누수 신호 없음)와 **LSTM forward 텐서 계약 검증**으로 확인하였다.

대응 노트북: notebooks/02_preprocessing.ipynb (30 셀) — 설계·구현·검증(V1-V15)이 실행 출력과 함께 담겨 있다.
파이프라인 위치: 01 EDA → **02 전처리** → 03 예측 → 04 스케줄링 → 05 평가
선행 문서: eda_report.pdf (모든 처방의 근거) 다음 문서: rul_model_report.pdf (표현이 성능이 되는 곳)

Contents

1	개요 — 무엇을 실행했나	2
2	센서 4분류 결과	2
3	Tabular 경로 — 특징 생성 결과	2
4	핵심 결과 — 죽은 특징 0개	3
5	Sequence 경로 — LSTM 텐서 생성 결과	4
6	통합 데이터셋 조립 — Unified	4
6.1	Unified Tabular	5
6.2	Unified Sequence	5
6.3	무결성 교차 검증 (U1-U9)	6
6.4	소비 가능성 smoke test — LightGBM 실학습 · LSTM 텐서 계약	6

7	검증 결과 — V1-V15 전부 통과	7
8	산출물	7
9	전처리 v2 — 루프 1 회차: 보완 EDA의 입력화	8
10	다음 단계	8

1 개요 — 무엇을 실행했나

9단계 파이프라인(S1-S9)과 두 출력 경로를 설계대로 구현하였다. **S1-S5(로드·RUL 라벨·condition_id·센서 4분류·조건 정규화)**를 공유하고 특징 구성에서 분기한다.

- **Tabular** (LightGBM 주 모델) — raw + 조건 정규화 z_+ + rolling(mean/std/delta/slope)
- **Sequence** (LSTM 병행) — 윈도우 텐서 (N, L, F) + 마스크

모든 결과는 data/raw/의 원본에서 직접 계산하였으며, 실행 로그의 수치를 그대로 수록한다.

2 센서 4분류 결과

FD별 train 기준 분류 결과는 설계 예측과 정확히 일치하였다(표 1).

Table 1: 센서 4분류 실행 결과 (설계 예측과 일치)

set	상수(제거)	조건지시자(제거)	근사상수	열화가능 n
FD001	s1, s5, s10, s16, s18, s19	(없음)	s6	15
FD002	(없음)	s1, s5, s18, s19	s16	17
FD003	s1, s5, s16, s18, s19	(없음)	s10	16
FD004	(없음)	s1, s5, s18, s19	s16	17





Figure 1: FD별 센서 4분류. 조건이 6개인 FD002/FD004는 상수가 사라지는 대신 조건 지시자가 나타난다.

3 Tabular 경로 — 특징 생성 결과

센서 파생 특징 수는 $8n(=raw\ n + z_+\ n + rolling\ 6n)$ 이며, 설계 예측과 일치한다(표 2). CSV 컬럼 수 = 메타 4(unit, cycle, dataset_id, condition_id) + 특징 + RUL.

Table 2: Tabular 산출물 (실행 결과)

set	n	센서 파생 $8n$	train 행 $\times$ 열	test 행 $\times$ 열
FD001	15	120	$20,631 \times 125$	$13,096 \times 124$
FD002	17	136	$53,759 \times 141$	$33,991 \times 140$
FD003	16	128	$24,720 \times 133$	$16,596 \times 132$
FD004	17	136	$61,249 \times 141$	$41,214 \times 140$

**Figure 2:** piecewise-linear RUL 라벨(FD001 unit 1). 초반은 125로 평탄, 이후 선형 감소.

4 핵심 결과 — 죽은 특징 0개

설계 단계에서 지목한 두 결함이 실측으로 해소되었다.

Table 3: 조건 정규화 품질 (실측). 죽은 특징 = 분산 $< 10^{-8}$ 인 컬럼.

set	죽은 특징	$\max z $	조건 지시자 $\mathbf{z}_-$ 컬럼
FD001	0	8.12	없음
FD004	0	10.00	없음

- **조건 지시자 제외** — s_1, s_5, s_{18}, s_{19} 에 $\mathbf{z}_-$ 를 만들지 않으므로, 직전 구현에서 FD004 특징의 **16.4%(28개)**였던 분산 0 컬럼이 **0개**가 되었다.
- **z -clip ± 10** — FD004의 $\max |z| = 10.00$ 은 근사상수 s_{16} 이 10에서 clip된 것이고, FD001은 $\max |z| = 8.12$ 로 clip에 닿지 않았다. 즉 **병리 센서만 억제하고 정상 신호는 보존한다** — clip 한계 ± 10 은 설계 시 정상 센서 최대치($\max |z| \approx 8.3$)를 실측해 정한 값이다.




Figure 3: (좌) z_{s11} — 조건 제거 후 RUL과 정렬. (우) z -clip ± 10 : 병리 센서 s_{16} (clip 전 $|z| \rightarrow 48$)만 억제되고 정상 센서 s_9 ($\max \approx 8.3$)는 온전히 보존된다.

5 Sequence 경로 — LSTM 텐서 생성 결과

윈도우 $L = 30$, 좌측 패딩 + 마스킹으로 시퀀스 텐서를 생성하였다(표 4). 특징 차원 F 는 단일조건 서브셋에서 z -센서 n 개, 다중조건에서 $n + 6$ (condition one-hot)이다.

Table 4: Sequence 산출물 (실행 결과). test는 엔진별 마지막 윈도우 1 개.

set	L	F	조건	X_{train}	X_{test}
FD001	30	15	단일	(20,631, 30, 15)	(100, 30, 15)
FD002	30	23	다중	(53,759, 30, 23)	(259, 30, 23)
FD003	30	16	단일	(24,720, 30, 16)	(100, 30, 16)
FD004	30	23	다중	(61,249, 30, 23)	(248, 30, 23)

test 엔진 중 $L = 30$ 보다 짧은 것(FD002 6 개, FD004 11 개)은 좌측 패딩되며, 그 구간 $\text{mask} = 0$ 으로 LSTM이 무시한다.




Figure 4: FD004 최단 test 엔진의 마스크(좌)와 z_{s11} 시퀀스(우). 짧은 궤적은 앞쪽이 패딩되고 mask로 가려진다.

6 통합 데이터셋 조립 — Unified

설계한 통합 구성을 실행하였다. FD별 산출물을 **합집합 17센서**(교집합 15 + s_{10} , s_{16}) 컬럼으로 정렬해 하나로 합치고, 통합 시퀀스 텐서를 생성하였다. 조건 정규화 z 통계는 **FD별로 유지**하였다

— 고장모드가 달라 같은 조건이라도 기준선이 다를 수 있고, 데이터셋 정체성은 `dataset_id`가 담당한다(pooled 통계는 A6 ablation에서 비교).

6.1 Unified Tabular

Table 5: 통합 tabular 산출물 (실행 결과)

항목	train	test
행 수	160,359 (= 4개 서브셋 합)	104,897
열 수	142 (메타 5 + 특징 136 + RUL)	141
엔진 수 (<code>engine_id</code>)	709	707

engine_id — 통합 분리의 필수 조건. raw unit은 FD 간 충돌한다 — unit 1–100은 네 서브셋 모두에 존재하므로, unit으로 group split하면 서로 다른 엔진이 한 그룹으로 묶인다. `engine_id = dataset_id_unit`으로 이를 해결하고, FD별 층화 분리(각 FD에서 75/25)로 모든 FD가 valid에 포함됨을 확인하였다(검침 0).

NaN 패턴 — ”없음”은 정보다. 해당 FD에 존재하지 않는 센서의 특징은 NaN으로 유지한다(대치 금지). FD 안에서 부분 NaN은 없다 — 컬럼은 전부 있거나 전부 없다(표 6). LightGBM은 결측을 분기에서 native하게 처리하며, 평균 대치는 ”그 FD에 없음”이라는 정보를 지운다.

Table 6: FD별 전체-NaN 특징 수 (실측 = 계획 예측)

	FD001	FD002	FD003	FD004
없는 센서	s10, s16	—	s16	—
NaN 특징 수 ($\times 8$)	16	0	8	0

6.2 Unified Sequence

Table 7: 통합 시퀀스 텐서 (실행 결과)

항목	값	비고
<code>X_train</code>	(160,359, 30, 27)	윈도우 $L = 30$
<code>X_test</code>	(707, 30, 27)	엔진별 마지막 윈도우
채널 $F = 27$	z 합집합 17 + cond one-hot 6 + ds one-hot 4	전 FD 동일 의미

NN은 NaN을 다루지 못하므로 없는 센서 채널은 **0으로 채운다** — z 공간에서 0은 ”조건 평균”이라 중립이며, dataset one-hot이 ”이 FD엔 그 센서가 없다”를 구분하게 한다. V15에서 FD001 행의 s10·s16 채널과 FD003 행의 s16 채널이 정확히 0임을 확인하였다.




Figure 5: 통합 train 구성(좌 — FD별 행 수, 총 160,359행/709엔진)과 FD별 NaN 특징 수(우 — 해당 FD에 없는 센서, 정보로 유지).

6.3 무결성 교차 검증 (U1–U9)

노트북 내부 assertion(V13–V15)과 별개로, 저장된 산출물을 외부 스크립트로 원천과 교차 대조하였다. 통합 tabular·통합 시퀀스·FD별 CSV·raw RUL 파일이 행 단위로 서로 정합함을 확인한다(표 8).

Table 8: 통합 산출물 무결성 교차 검증 (외부 재검, 전부 통과)

#	검증 내용	결과
U1	시퀀스 y = tabular RUL (전행, 순서 포함)	PASS
U2	시퀀스 마지막 시점 = tabular z_{-} 값 (4개 FD 표본 센서)	PASS
U3	zero-fill 위치 (FD001: $s_{10} \cdot s_{16}$ / FD003: s_{16} 채널 = 0)	PASS
U4	mask 합 = min(엔진 내 순번, 30) (전행)	PASS
U5	condition one-hot = condition_id (전행)	PASS
U6	dataset one-hot 블록 정합 (FD 순서·합 = 1)	PASS
U7	test true_RUL = RUL_FDxxx.txt 순서 concat (100/259/100/248)	PASS
U8	통합 z_{-} = FD별 CSV z_{-} (정렬이 값을 훼손하지 않음)	PASS
U9	시퀀스 텐서 finite (NaN/inf 없음)	PASS

6.4 소비 가능성 smoke test — LightGBM 실학습·LSTM 텐서 계약

”두 모델이 이 데이터를 실제로 소비할 수 있는가”를 형태 검증이 아니라 실행으로 확인하였다.

LightGBM (실제 학습). 통합 CSV를 그대로 로드해 dataset_id·condition_id를 native categorical로, NaN을 대치 없이 넣고, engine_id 기준 FD별 층화 분리(75/25)로 120 tree를 학습하였다(소요 9초).

valid RMSE = 15.28 (FD001 14.66 / FD002 16.96 / FD003 11.25 / FD004 15.40)

이는 튜닝 없는 smoke test이지 벤치마크가 아니다. 다만 두 가지 신호가 중요하다: (i) NaN·categorical·엔진 분리를 포함한 전체 파이프라인이 오류 없이 학습되고, (ii) FD001 RMSE가 표준 기준선(12–14) 근처이되 의심스럽게 낮지 않다 — 누수가 있었다면 한 자릿수로 떨어졌을 것이다. 정식 학습·튜닝·ablation은 03에서 수행한다.

LSTM (텐서 계약). mask 게이팅을 포함한 LSTM cell forward(numpy 구현)로 통합 텐서 배치 (512, 30, 27)을 소비시켜 유한한 출력 (512, 1)이 나옴을 확인하였다 — `shape·dtype(float32)·mask 의미·입력 스케일( $z \pm 10$ , one-hot 0/1)`이 순환 모델 계약에 부합한다. **torch는 아직 미설치**이므로 실제 LSTM 학습은 03에서 `pip install torch` 후 진행한다(데이터 쪽 준비는 완료).

7 검증 결과 — V1–V15 전부 통과

전처리 실행 중 모든 assertion이 통과하였다(표 9). 하나라도 실패하면 파이프라인이 중단되도록 구현하였다.

Table 9: 검증 assertion 실행 결과

#	검증	결과
V1	조건 수 (FD001/003=1, FD002/004=6)	PASS
V2	퇴화 특징 없음 ($\sigma > 10^{-8}$)	PASS
V3	z -clip ($\max z \leq 10$)	PASS
V4	특징 NaN 없음	PASS
V5	누수 컬럼 (total_life 등) 부재	PASS
V6	엔진 단위 분리 (겹침 0)	PASS
V8	rolling 미래 미사용 (스파이크 단위 테스트)	PASS
V9	RUL 범위 [0, 125]	PASS
V10	조건 지시자 z_* 부재	PASS
V11	시퀀스 텐서 정렬	PASS
V12	mask 정합 (0/1, 마지막 시점 = 1)	PASS
V13	(통합) 컬럼·행수·NaN 패턴 {16, 0, 8, 0}, 부분 NaN 없음	PASS
V14	(통합) engine_id 유일 (709/707)·층화 분리 겹침 0	PASS
V15	(통합 시퀀스) shape·zero-fill 위치·mask	PASS

V8은 인위적 시퀀스의 마지막 시점에 스파이크를 주입해, 그 이전 rolling 값이 변하지 않음을 확인하는 방식으로 검사하였다 — 누수는 성능 지표만으로는 드러나지 않기 때문이다.

8 산출물

Table 10: 생성된 산출물

경로	파일	내용
Tabular (FD 별)	data/processed/{train,test}_features_{FD}.csv	메타 + 특징 + RUL
Tabular (통합)	data/processed/{train,test}_features_unified.csv	합집합 정렬 + engine_id
Sequence (FD 별)	data/processed/seq/{FD}_{train,test}.npz	X, y, mask, unit
Sequence (통합)	data/processed/seq/unified_{train,test}.npz	$F = 27$, engine/dataset 포함
Manifest	feature_manifest.json, seq/seq_manifest.json	unified 항목 포함
그림	reports/figures/preprocessing/P1--P5.png	본 보고서 그림

feature_manifest.json은 FD별 센서 분류와 특징 목록을 담으므로, 03_rul_model이 컬럼명을 하드코딩하지 않고 참조할 수 있다. (data/processed/는 용량이 크고 재생성 가능하므로 Git에 올리지 않는다.)

9 전처리 v2 — 루프 1회차: 보완 EDA의 입력화

모델링 라운드 이후, EDA 최종본의 보완 EDA 절(확인·기각·역방향 발견)에서 도출한 특징 4군을 추가했다. 모든 특징은 기존 unified 산출물의 z_ 위에서 과거 전용으로 파생된다(scripts/run_v2_features.py).

Table 11: v2 특징 4군 (28개) — 각각의 EDA 계보

특징군	정의	EDA 근거
G1 자기-기준선 (17)	$b_s = z_s - \overline{z_s[\text{첫} \leq 10\text{cyc}]}$ (expanding, 과거 전용)	보완 EDA: 초기 제조 오프셋 = 열화량의 18–22%
G2 건강지표 (4)	$H = \text{mean}_s b_s $, H -ma20, 누적 손상 $\sum \text{relu}(H-0.3)$, onset 경과	piecewise 구조의 입력화, 단조 드리프트의 총량화
G3 결합 출현 (1)	$\text{rolling corr}_{20}(z_{s9}, z_{s14})$	보완 EDA: 결합이 말기에 출현 (0.09→0.63)
G4 모드 크기 (5)	$ b_s $, $s \in \{s7, s12, s15, s20, s21\}$	§7.2 고장모드별 방향 반전 → 부호 불변화

누수 검증 (V-v2). 마지막 cycle의 센서를 +100으로 오염시켜도 그 이전 모든 시점의 v2 특징 28개가 전부 불변임을 확인했다(스파이크 단위 테스트, 전 특징 PASS). 자기-기준선은 첫 10 cycle 구간에서 expanding mean을 쓰므로 초기 구간도 미래를 참조하지 않는다.

성능 효과. v2 특징의 모델 성능 기여(valid 15.19 → 10.29, test 11.65)와 적대적 검증(시드 재현성·물리 해석)은 rul_model_report.tex의 "루프 1회차" 절에 기록되어 있다.

v3 (루프 2회차). FD003 격차 mini-EDA(onset 상대시점 0.45 ± 0.17 로 유일하게 낮고 산포 큼)에서 다중 임계 onset 시계($\theta=0.2/0.5$) + 도달 플래그 + 경계 마진 4특징을 추가했다(scripts/run_loop2.py). 효과: valid 10.29 → 9.29, FD003 9.26 → 6.64 — 상세는 모델 보고서 루프 2회차 절. fleet 예측 CSV는 2회차 혼합(v3-LGBM×LSTM-D) 모델로 갱신되었다.

10 다음 단계

- 03_rul_model — FD별 모델과 통합 모델(unified CSV, engine_id 기준 분리)을 모두 학습. overall + FD별 RMSE, PHM08 병기.
- Ablation A0–A10 수행 — 조건 지시자 제외, 근사상수 유지, 조건 정규화, rolling, clip 한계, 통합 구성, LSTM 등 전처리 가정 검증.
- 기준선 확인 — FD001 RMSE 약 12–14. 크게 낮으면 누수부터 재점검(V5–V8). smoke test에서 이미 FD001 14.66으로 기준선 근처임을 확인(정식 튜닝으로 개선 여지).
- LSTM 경로 — pip install torch 후 seq/unified_{train,test}.npz로 학습 (데이터 계약은 검증 완료).

재현. notebooks/02_preprocessing.ipynb 실행 시 본 보고서의 CSV·텐서·그림이 생성된다. 근거. eda_report.tex(EDA 최종본 — 모든 설계 결정의 출처).