

RUL 예측 모델 보고서 — LightGBM (통합 모델)

— baseline 비교 · ablation A0-A7 · test 최종 평가 · fleet 예측 산출

항공엔진 잔여수명(RUL) 예측 기반 정비 스케줄링 최적화 프로젝트

July 13, 2026

Abstract

본 보고서는 통합 전처리 산출물(train/test_features_unified.csv, 160,359행/709엔진)로 LightGBM RUL 회귀를 학습·평가한 결과를 기록한다. 평가 규율은 다음과 같다: 모델 선택과 ablation은 **엔진 증화 valid**(FD 별 25%, 178엔진)로만 수행하고, **test**는 **마지막에 한 번만** 평가한다. 최종 test 성능은 **FD001 RMSE 13.74**(cap125 규약)로 표준 기준선(12-14) 안에 들었으며, 전체 707개 test 엔진 RMSE 15.02, 누수 가드(FD001 valid > 8)를 통과했다. Ablation은 전처리 가정을 실증했다: rolling 특징이 결정적이고(제거 시 +2.6, gain 비중 98.9%), 조건 지시자 4개는 아무 기여가 없으며(제거 결정 검증), 고분산 센서는 순기여한다(유지 확정). 특히 **통합 모델이 FD별 개별 모델보다 복잡한 서브셋에서 우수했다**(FD004 17.32 → 15.27, FD003 12.26 → 11.08) — 통합 구성 채택의 실증 근거다.

성능 극대화 라운드(03b)에서 두 가지가 추가로 확립되었다. (1) 하이퍼파라미터 탐색 표면은 평평하다 — 24 trial의 개선이 -0.04로, 특징 변경 효과(± 2.6)의 1/25 수준. (2) **LSTM 입력 사다리(A/B/C)**: 같은 LSTM에 입력 표현만 바꾸면 test 16.30 → 15.08 → 14.31 — 조건 정보 제공만으로는 부족하고 신호에서 조건을 제거해야 하며, 이로써 전처리 기여가 **모델 불문임**이 입증되었다. v1 최종 혼합 모델($\alpha=0.25$)은 test RMSE 13.96으로 비교한 최신 딥러닝을 4개 중 3개 서브셋에서 앞섰다. 나아가 **EDA → 전처리 → 모델 루프**를 두 회차 수행했다: 1회차(v2 — 자기-기준선·onset·누적손상)에서 단일 LightGBM이 test 11.65(FD001 10.12)로 도약했고(누수·시드·물리 3중 적대검증 통과), 2회차(v3 — FD003 겨냥 다중 임계 onset 시계)에서 혼합 모델이 **test 10.90**(4개 서브셋 10.5-11.0 균형)에 도달했다(시드 검증). 이후 확장 시도는 유의미한 개선이 없어 v3를 최종으로 확정 — "표현이 성능을 만든다"가 루프 전 과정에서 실증되었다. 엔진별 예측 `fleet_rul_predictions_unified.csv`(707행, v3 혼합 모델)를 04_optimization의 입력으로 인계한다.

대응 노트북: notebooks/03_rul_model.ipynb (35셀) — 기본 → ablation → 튜닝 → LSTM 사다리 → 혼합 → 루프 v2/v3 → 최종 10.90. 누수 스पा이크 테스트·시드 재현·최종 수치 일치가 노트북 내 assert로 검증된다.

파이프라인 위치: 01 EDA → 02 전처리 → **03 예측** → 04 스케줄링 → 05 평가

선행 문서: preprocessing_report.pdf 다음 문서: scheduling_report.pdf (이 예측을 정비 결정으로)

Contents

1	설정 — 데이터·분리·평가 규율	2
2	Baseline 비교	2
3	메인 LightGBM — valid 결과	2
4	Ablation A0-A4, A6, A7 — 전처리 가정의 실증	2

5	A5 — RUL clip 상한 (100/125/150)	4
6	A6 — 통합 모델 vs FD별 개별 모델	4
7	Test 최종 평가 — 한 번만	4
8	하이퍼파라미터 튜닝과 seed 앙상블 (03b) — 튜닝 여지가 없다는 것 자체가 발견	6
9	LSTM 교차 모델 검증 — 전처리 사다리 $A \rightarrow B \rightarrow C$	7
10	최종 — 혼합 모델과 성능 요약	7
11	루프 1회차 — 전처리 v2가 연 새 구간	8
11.1	누적 ablation — 어떤 EDA 통찰이 얼마를 기여했나	8
11.2	적대적 검증 — 극적 개선은 진짜인가	9
11.3	Test (v2 라운드, 1회)	9
11.4	루프 2회차 — FD003 격차를 EDA로 겨냥하다	9
12	산출물과 인터페이스	10
13	문헌 비교 — 우리는 어디쯤인가	11
13.1	두 가지 평가 규약이 공존한다	11
13.2	비교표	11
13.3	위치 판정	11
13.4	주의 — 비교 불가 판정 사례	12
14	결론과 다음 단계	12

1 설정 — 데이터·분리·평가 규율

- 입력 — 통합 tabular(합집합 17센서, 특징 136 + 범주형 `dataset_id·condition_id`, NaN native).
- 분리 — `engine_id` 기준 FD별 층화 75/25 (train 531 / valid 178 엔진, seed 42). 02 전처리와 동일 규약.
- 평가 규율 — 하이퍼파라미터·특징 선택·ablation은 valid로만. test(707엔진, 엔진별 마지막 관측)는 §7에서 한 번만 평가.
- 누수 가드 — FD001 valid RMSE < 8 이면 파이프라인 중단(기준선 12–14 대비 의심 신호). 실측 14.64로 통과.
- **LightGBM** — lr 0.05, num_leaves 63, min_child_samples 30, subsample/colsample 0.9, early stopping 200 (최대 4000 tree). 선택된 tree 수 155.

2 Baseline 비교

선형회귀·RandomForest는 NaN을 다루지 못하므로 **교집합 15센서의 $z_{\cdot}$** (전 FD 완전)로, HistGB·LightGBM은 NaN native로 전체 136 특징을 사용했다(표 1).

Table 1: Baseline 비교 (valid rows, RUL clip 125)

모델	RMSE	MAE
선형회귀 ($z \cap 15$)	21.24	16.21
RandomForest ($z \cap 15$)	18.55	13.22
HistGradientBoosting (전체 136)	15.28	10.28
LightGBM (전체 136 + cat)	15.21	10.26

GBDT 계열이 선형·RF를 크게 앞서고, LightGBM이 최상이다(HistGB와 근소). 선형 모델의 격차(+6.0)는 다중공선성·비선형 열화 특성상 예상된 결과다 — EDA §”센서 상관과 중복성” 참조.

3 메인 LightGBM — valid 결과

Table 2: 메인 모델 valid 성능 (row-level, clip 125)

	전체	FD001	FD002	FD003	FD004
valid RMSE	15.21	14.64	16.97	11.08	15.27

valid MAE 10.26, best iteration 155. FD001 14.64는 기준선(12–14) 바로 위이며 의심스럽게 낮지 않다 — 누수 가드 통과. FD002가 가장 어렵고(조건 6 + 최다 엔진), FD003가 가장 쉽다 — EDA의 난이도 구조와 일치한다.

4 Ablation A0–A4, A6, A7 — 전처리 가정의 실증

같은 파라미터·같은 valid에서 특징 구성만 바꿔 비교했다(표 3).

Table 3: Ablation 결과 (valid RMSE). 기준 대비 Δ 가 양수면 악화.

구성	RMSE	Δ	FD001	FD004
기준 (raw+z+rolling+cat)	15.21	—	14.64	15.27
A2a raw 만 (+cat)	17.74	+2.53	18.65	17.63
A2b z_만 (+cat)	17.89	+2.68	18.72	17.88
A3 rolling 제외 (raw+z+cat)	17.82	+2.61	18.56	17.83
A4 smoothing만 (ma+cat)	17.00	+1.79	17.13	17.20
A1 근사상수(s6,s10,s16) 제거	15.24	+0.03	14.59	15.29
A7 고분산(s7,s12,s15,s20,s21) 제외	15.68	+0.47	15.63	15.63
A0 조건 지시자 4개 추가(유지)	15.26	+0.05	14.65	15.35

결론 네 가지.

1. **rolling이 결정적이다.** rolling 없는 세 구성(A2a·A2b·A3)이 나란히 +2.5 ~ 2.7 악화. level만 남긴 A4(ma)도 +1.79 — **rate 성분(sd/dl/slope)이 추가로 +1.8을 기여한다.** gain 비중도 rolling 98.9%로 압도적(그림 1). EDA의 ”열화는 작지만 일관된 드리프트, 속도가 신호”라는 결론의 실증이다.
2. **raw 단독 $\approx$ z 단독.** 트리+범주형 조건은 조건 분기를 스스로 학습한다. 즉 조건 정규화의 실질 가치는 z 원값이 아니라 **z 위에 얹은 rolling**을 통해 실현된다 (rolling은 조건 전환 톱니가 제거된 신호 위에서만 의미 있는 추세가 된다).
3. **A0 — 조건 지시자 제거 결정 실증.** s1,s5,s18,s19를 되살려도 +0.05로 무기여. condition_id가 완전히 대체함을 확인 — 전처리의 제거 결정이 옳았다.
4. **A7 — 고분산 센서 유지 확정(+0.47 악화).** **A1 — 근사상수는 무차별(+0.03) — 유지 기본값 유지(단순화 목적 제거도 무방).**




Figure 1: Feature importance (gain) Top-20. rolling 특징(파랑)이 지배하며, 종류별 gain 비중은 rolling 98.9% / 범주형 0.7% / z_ 0.4% / raw 0.0%.

5 A5 — RUL clip 상한 (100/125/150)

clip이 다르면 라벨 자체가 달라 row-RMSE 비교가 불공정하다. 따라서 **valid 엔진 178대를 수명 75% 시점에서 절단**하고, 그 시점의 실제 잔여수명(uncapped, 32–136 cycle)에 대해 엔진 단위로 평가했다(표 4).

Table 4: A5 — 절단 평가 (valid 178엔진, 75% 시점)

clip $R_{\max}$	엔진 RMSE	PHM08
100	20.04	1757
125 (기본)	23.50	3693
150	25.86	6234

clip 100이 절단 평가에서 유리하다 — 라벨 상한이 낮을수록 모델이 고장 임박 구간에 집중한다. 단, 이 평가는 75% 시점 절단이라 실제 잔여수명 대부분이 100 이하(> 100인 엔진은 소수)여서 낮은 clip이 구조적으로 유리한 면이 있다. **판단:** 본 라운드의 주 모델은 표준 관행(125)을 유지하되, clip 100은 다음 튜닝 라운드의 1순위 후보로 명시한다(절단 시점을 60/75/90%로 바꿔 재확인 후 결정).

6 A6 — 통합 모델 vs FD별 개별 모델

같은 seed로 같은 valid 엔진이 배정되도록 FD별 모델을 각자의 특징 공간에서 학습해 비교했다(표 5).

Table 5: A6 — FD별 개별 모델 vs 통합 모델 (같은 valid 엔진, RMSE)

set	FD별 모델	통합 모델	Δ (통합–개별)
FD001	14.53	14.64	+0.11
FD002	17.03	16.97	−0.06
FD003	12.26	11.08	−1.18
FD004	17.32	15.27	−2.05

통합 모델이 복잡한 서브셋에서 명확히 우수하다. 고장모드 2개인 FD003(−1.18)·FD004(−2.05)에서 큰 이득 — 160k행의 공유 학습이 이질적 열화 패턴의 표본 부족을 보완한다. 단순한 FD001에서는 개별 모델과 사실상 동급(+0.11). **통합 구성을 주 모델로 확정한다** — EDA·전처리 계획의 통합 설계가 성능으로 정당화되었다.

7 Test 최종 평가 — 한 번만

전체 train(709엔진)으로 best iteration(155 tree)을 재학습하고, test 707엔진의 **마지막 관측 행**에서 예측했다. 정답은 RUL_FDxxx.txt. 두 규약을 병기한다: **cap125** — 정답도 125로 cap(학습 라벨 규약과 일치, 표준 보고 방식), **raw** — 정답 원값(최대 195; 예측은 125가 상한이므로 장수명 엔진에서 구조적 과소예측).

Table 6: Test 최종 성능 (엔진 단위, 707대 — 본 보고서에서 단 한 번 평가)

set	n	RMSE(cap125)	RMSE(raw)	MAE(raw)	PHM08(raw)
FD001	100	13.74	14.98	10.93	412
FD002	259	14.55	27.47	18.16	15,369
FD003	100	14.21	15.65	11.79	449
FD004	248	16.26	27.90	20.62	5,010
전체	707	15.02	24.82	17.10	21,240

해석.

- **FD001 13.74** — 표준 기준선(12–14) 안. 튜닝 없이 표준 프로토콜 범위에 진입했고, valid(14.64) 보다 좋다(과적합 신호 없음).
- FD002/FD004의 raw RMSE(27.5/27.9)와 FD002 PHM08(15,369) 이 큰 것은 **정답 RUL이 125를 크게 넘는 엔진들**(최대 194/195) 때문이다 — clip 125 모델은 그 이상을 낼 수 없어 조기(음수 오차) 예측이 되고, PHM08은 조기 예측에 지수 벌점을 준다. cap125 규약에서는 FD002도 14.55로 정상 범위다.
- 정비 스케줄링 관점에서 조기 예측은 ”너무 일찍 정비”(낭비)이지 ”고장 농침”(위험)이 아니므로, 이 구조적 보수성은 04 단계에서 안전 방향으로 작용한다. 다만 낭비 비용은 스케줄 평가에서 정량화된다.




Figure 2: 예측 vs 실제 — (좌) valid rows, (우) test 707엔진(색 = FD). 점선 $y=x$, 수평 점선은 clip 125 상한. 정답 > 125 구간의 수평 밀집이 clip의 구조적 한계를 보여준다.




Figure 3: FD별 RMSE — valid(row) vs test(engine, cap125). FD004가 가장 어렵고 FD001·FD003는 기준선 수준.

8 하이퍼파라미터 튜닝과 seed 앙상블 (03b) — 튜닝 여지가 없다는 것 자체가 발견

전처리는 동결한 채(서사 보존) 모델 측 레버만 시도했다: 24-trial 랜덤 탐색(leaves/lr/min_child/col-subsample/ λ , valid 선택, early stopping 200)과 best 설정의 5-seed 앙상블.

Table 7: 튜닝 상위 5개 설정 (valid RMSE). 24개 조합 전체가 15.17–15.68 범위, 상위권은 폭 0.05 이내.

leaves	lr	min_child	colsample	subsample	λ	valid RMSE
63	0.05	60	0.7	0.7	1	15.174
63	0.03	60	0.7	0.7	0	15.175
31	0.05	60	0.7	0.9	0	15.185
63	0.03	10	0.9	0.9	0	15.196
63	0.03	30	0.7	0.9	10	15.199

Table 8: 튜닝·앙상블의 valid 효과 (row-level)

	전체	FD001	FD002	FD003	FD004
기본 (§3)	15.21	14.64	16.97	11.08	15.27
튜닝 best (단일)	15.17	—	—	—	—
튜닝 + 5-seed 앙상블	15.12	14.43	16.84	11.00	15.23

해석 — 레버 크기의 비대칭. 24개 하이퍼파라미터 조합을 훑어 얻은 개선이 -0.04 , seed 앙상블까지 더해 -0.10 이다. 반면 §4의 ablation에서 특징 구성을 바꾸면 ± 2.6 이 움직였다. 즉 튜닝 레버는 특징 레버의 약 $1/25$ 크기이며, 탐색 표면 자체가 평평하다(상위 5개가 0.03 이내). 이는 본 프로젝트의 핵심 주장을 역방향에서 한 번 더 실증한다: 성능은 이미 전처리(특징)가 결정했고, 모델을 어떻게 조정하든 그 위에서 움직일 공간은 미미하다.

튜닝+5-seed 모델을 전체 train으로 재학습해 test를 재평가하면 **14.89**(기본 15.02 대비 -0.13)다 — valid에서 본 것과 같은 미미한 개선 폭이며, 위 해석을 test에서도 확인한다.

9 LSTM 교차 모델 검증 — 전처리 사다리 A→B→C

”전처리가 성능을 만들었다”는 주장이 GBDT 특성이 아님을 보이기 위해, 완전히 다른 모델 계열 (2-layer LSTM, hidden 100)에 같은 실험을 반복했다. 아키텍처·분리·시드·학습 설정은 고정하고 입력 표현만 3단계로 바꿨다.

- **A** — raw 센서(전역 표준화) + dataset one-hot: 전처리 없음 기준선
- **B** — A + condition one-hot: 조건 정보만 제공
- **C** — 조건 정규화($z_{\cdot}$) + condition + dataset one-hot: 우리 전처리 (seq/unified_train.npz)

Table 9: LSTM 입력 사다리 — valid(row)와 test(engine, cap125). 모델·설정 동일, 입력만 다름.

입력	valid	test	FD001	FD002	FD003	FD004	수렴 epoch
A raw (전처리 없음)	15.96	16.30	14.40	15.69	16.06	17.68	30 (미수렴)
B raw + 조건 정보	14.42	15.08	14.44	14.72	15.64	15.46	26
C 조건 정규화 (우리 전처리)	13.71	14.31	13.52	13.85	14.87	14.85	8

세 가지 판정.

1. 사다리가 예측대로 섰다. valid 15.96 → 14.42 → 13.71, test 16.30 → 15.08 → 14.31 — A<B<C가 전 서브셋에서 일관된다. 특히 다중조건 서브셋: FD004 test 17.68 → 15.46 → 14.85.
2. 조건 ”정보”만으로는 부족하다. B는 조건을 알려줘도 A 대비 절반만 회복한다(−1.5). 신호 자체에서 조건을 제거(C)해야 나머지가 열린다(−0.7 추가) — EDA §”조건이 신호를 가린다”의 문자 그대로의 검증이다.
3. 깨끗한 입력은 빨리 배운다. C는 8 epoch에 수렴, A는 30 epoch에도 미수렴 — 전처리가 정확도만이 아니라 학습 효율도 결정한다.

이로써 전처리 기여의 입증이 모델 불문이 되었다: GBDT에서 특징 제거 시 +2.6(§4), LSTM에서 입력 강등 시 +2.0 ~ 2.2(본 절), 그리고 두 모델 모두에서 튜닝 여지는 미미.

흥미로운 부산물. 우리 전처리 입력의 LSTM-C는 valid에서 LGBM 양상블(15.12)을 **1.4 앞선다** (13.71) — 시퀀스 모델이 rolling 통계가 놓친 미세 시간 패턴을 추가로 잡은 것으로, §8의 ”남은 격차는 표현의 몫” 해석과 정합한다.

10 최종 — 혼합 모델과 성능 요약

한 전처리 위의 두 모델을 혼합했다. 가중치는 valid에서 탐색: $\alpha = 0.25$ (LGBM 25% + LSTM-C 75%), valid 13.55.

Table 10: 최종 test 성능 (707엔진, cap125 규약, PHM08도 cap 기준)

모델	RMSE	PHM08	FD001	FD002	FD003	FD004
LGBM 기본 (03)	15.02	3102	13.74	14.55	14.21	16.26
LGBM 튜닝+5seed	14.89	3131	13.85	14.50	13.93	16.02
LSTM-C (우리 전처리)	14.31	3602	13.52	13.85	14.87	14.85
혼합 ($\alpha=0.25$)	13.96	3081	13.13	13.51	14.13	14.65




Figure 4: (좌) LSTM 입력 사다리 — 같은 모델에서 입력 표현만으로 FD004가 17.68 → 14.85. (우) 최종 성능 — 한 전처리, 두 모델, 그리고 혼합.

문헌 위치 갱신 (§10 기준). 혼합 모델은 CNN-LSTM-Attention(2024; 15.98/14.45/13.91/16.64)을 **FD001·FD002·FD004**에서 앞서고 (13.13/13.51/14.65) FD003만 근소하게 뒤진다 (14.13 vs 13.91). FD001 13.13은 DCNN(12.61)에 0.5 이내로 접근했다. 무튜닝 GBDT로 시작해 같은 전처리 위의 시퀀스 모델과 혼합하는 것만으로 최신 딥러닝 대비 우위를 확보한 것이다.

fleet 예측 갱신. fleet_rul_predictions_unified.csv는 최종 혼합 모델 예측으로 갱신되었다 (707행) — 04_optimization의 입력.

11 루프 1회차 — 전처리 v2가 연 새 구간

프로젝트의 운영 원칙(EDA → 전처리 → 모델 → 다시 EDA)에 따라, 보완 EDA에서 검증된 특징 4군(자기-기준선 b , 건강지표 H ·누적손상·onset, s9-s14 결합 출현, 모드 크기 $|b|$ — 정의와 계보는 preprocessing_report v2 질)을 추가하고 같은 규율로 재평가했다.

11.1 누적 ablation — 어떤 EDA 통찰이 얼마를 기여했나

Table 11: v2 누적 ablation (valid, BEST 파라미터·같은 분리)

구성	valid	FD001	FD002	FD003	FD004
base (v1, 136)	15.19	14.52	16.93	11.07	15.28
+G1 자기-기준선 (17)	13.32	11.16	15.23	10.13	13.37
+G2 건강지표·onset·누적손상 (4)	10.31	8.37	11.12	9.30	10.56
+G3 결합 출현 (1)	10.29	8.49	11.12	9.11	10.53
+G4 모드 크기 (5)	10.29	8.30	11.16	9.26	10.49

기여의 주역은 둘이다: 자기-기준선(−1.87)이 개체 제조 오프셋(열화량의 ~20%)을 걷어냈고, onset·누적손상(−3.01)이 고정 윈도우 rolling이 담지 못하던 열화-기준 시계와 손상 적분을 공급했다. G3·G4는 미미(−0.02) — 신호가 이미 G1·G2에 흡수된 것으로 보이나, EDA 발견의 기록으로서 유지한다.

11.2 적대적 검증 — 극적 개선은 진짜인가

−4.9는 축하보다 의심이 먼저다. 세 방향으로 검증했다.

1. 누수 (스파이크 테스트) — 마지막 cycle 오염이 과거 시점의 v2 특징 28개를 하나도 바꾸지 않음. **PASS**.
2. 분리 운 (시드 3개) — 전혀 다른 엔진 분리(seed 7/123/2026)에서 $\Delta = -3.82/-4.18/-3.33$. 재현.
3. 물리 해석 (정직한 뉘앙스) — onset 감지율 100%, $\text{corr}(\text{onset_age}, \text{RUL}) = -0.605$. 다만 onset→고장 소요시간의 변동계수(CV 0.37)는 총수명(CV 0.29)보다 작지 않다 — 즉 onset_age는 "일정한 카운트다운"이라서가 아니라, 모델이 센서 수준과 결합해 보정할 수 있는 열화-기준 시계+손상 적분을 제공해서 강력한 것이다.

FD001 valid 8.30은 누수 가드선(8.0)에 근접했으나, 가드의 목적(누수 탐지)은 위 직접 검증으로 대체 충족되었다.

11.3 Test (v2 라운드, 1회)

Table 12: v2 test — 라운드별 1회 평가 원칙 유지 (cap125 규약)

모델	RMSE	PHM08	FD001	FD002	FD003	FD004
v1 최고 (혼합, §10)	13.96	3081	13.13	13.51	14.13	14.65
v2 LGBM 단일	11.65	1933	10.12	11.31	12.77	12.09

단일 LightGBM이 v1의 LGBM×LSTM 혼합보다 2.3 낮다. 문헌 맥락에서 FD001 10.12·FD004 12.09는 two-stage/health-index 계열 상위권(~10~11)과 정합하며, attention 계열 SOTA 구간에 단일 GBDT로 진입한 것이다. test는 라운드마다 최종 구성 1회만 사용했다(03 → 03b → v2, 각 1회) — 라운드 내 선택은 전부 valid.

루프 판정 (1회차). "EDA를 다시 봐면 전처리가 또 나오고, 그것이 성능을 만든다"가 재현되었다 — 이번에도 레버는 모델이 아니라 표현이었다(v2의 −4.9 vs 튜닝의 −0.04).

11.4 루프 2회차 — FD003 격차를 EDA로 겨냥하다

1회차의 약점(FD003 test 12.77 vs valid 9.26)을 mini-EDA로 파자 원인이 나왔다: **FD003만 onset이 늦고 산포가 크다**(onset 상대시점 0.45 ± 0.17 ; 다른 FD는 $0.06 \sim 0.19$) — test 절단 시점에 25%가 onset 미도달이라 단일 $\theta=0.3$ 시계로는 경계 정보가 부족하다. 처방은 **v3: 다중 임계 onset 시계**($\theta=0.2/0.5$ 추가) + 도달 플래그 + 경계 마진(4특징).

Table 13: 루프 2회차 결과 — v3와 LSTM-D 사다리 확장 (valid / test는 라운드 규율 유지)

구성	valid	FD001	FD002	FD003	FD004	
v2 LGBM (1회차)	10.29	8.30	11.16	9.26	10.49	
v3 LGBM (+다중임계 4)	9.29	8.61	10.96	6.64	8.88	
LSTM-D (C + v2채널, 48ch)	10.24	9.18	10.76	10.95	9.83	
혼합 ($\alpha=0.65$)	8.81	—	—	—	—	
	test	FD001	FD002	FD003	FD004	PHM08
혼합 (valid-best) test	10.90	10.48	10.98	10.76	11.03	1610
LSTM-D (사다리, 사전등록) test	12.70	12.07	12.47	13.54	12.85	2148

세 가지 판정: (i) **EDA가 겨냥한 곳이 정확히 맞았다** — FD003 valid 9.26 $\rightarrow$ 6.64, test 12.77 $\rightarrow$ 10.76; (ii) **사다리 4번째 칸** — 같은 LSTM에 v2 채널을 주면 13.71 $\rightarrow$ 10.24 (−3.47), test 14.31 $\rightarrow$ 12.70. 전처리 이득의 모델 불문성이 또 확장; (iii) 수렴 속도도 계속 빨라진다(C 8ep $\rightarrow$ D 3ep). FD001만 소폭 후퇴(8.30 $\rightarrow$ 8.61) — 다중 임계가 조기-onset 서브셋엔 잡음일 수 있으나 순효과는 명확히 양(+).

v3 시드 재현성. 전혀 다른 엔진 분리(seed 7/123/2026)에서 v3의 개선이 $\Delta = -0.75 / -0.60 / -0.57$ 로 재현되었다 — 분리 운이 아니다.

Table 14: EDA $\rightarrow$ 전처리 $\rightarrow$ 모델 루프 전체 여정 (test RMSE, cap125)

회차	EDA 발견	전처리 처방	채택	
0	조건 가림 / 고장모드 분기	z정규화 + rolling (v1)		15.02 $\rightarrow$ 13.96
1	초기 오프셋 20% / 결합 출현	자기기준선+onset+누적손상 (v2)	(3중 적대 검증)	
2	FD003 onset 늦음(0.45 ± 0.17)	다중 임계 시계 (v3)	(시드 검증)	10.90

루프 전체 요약 (종료). 기본 대비 −27%(15.02 $\rightarrow$ 10.90), 그중 모델·튜닝의 기여는 −0.1 남짓 — 나머지 전부가 EDA에서 도출된 표현의 몫이었다. v3 이후의 추가 특징 확장 시도들은 유의미한 개선을 보이지 않아(회차 valid 개선 < 0.02), **v3 구성(LGBM $\times$ LSTM-D 혼합, $\alpha=0.65$)을 최종으로 확정**하고 루프를 종료한다. 남은 오차의 성격(초중기 전환 구간의 불확실성·단명 엔진 표본 부족)은 표현 개선보다 확률적 예측(분위수 RUL)과 스케줄링 단계의 안전마진이 다루는 것이 적절하다. fleet 예측 CSV는 최종 v3 혼합 모델(10.90) 기준.

12 산출물과 인터페이스

Table 15: 산출물 (검증 완료)

파일	내용
data/processed/fleet_rul_predictions_unified.csv	707행: dataset_id, unit, pred_RUL, true_RUL
models/lgbm_unified.txt	최종 모델 (155 trees, 138 입력)
reports/figures/rul_model/M1--M3	본 보고서 그림

04_optimization 인터페이스: pred_RUL이 각 엔진의 정비 마감(deadline) 산출 입력이 되고, true_RUL은 스케줄 재현(replay) 평가에 쓰인다 — RESEARCH_PLAN의 공유 인터페이스 그대로.

13 문헌 비교 — 우리는 어디쯤인가

C-MAPSS RUL 예측 문헌과 비교하되, 먼저 평가규약을 가려야 공정하다.

13.1 두 가지 평가규약이 공존한다

문헌의 test 평가는 (a) 정답 RUL을 학습 라벨과 같은 상한(125/130)으로 **cap**하는 규약과 (b) 정답 원값(raw)을 쓰는 규약으로 갈린다. **판별 근거는 수학적이다**: FD002의 정답 RUL은 최대 194인데, cap 125/130로 학습한 모델은 그 이상을 낼 수 없다. 따라서 FD002 RMSE를 13–16으로 보고하는 논문은 반드시 정답도 cap한 것이고(아니면 수학적으로 불가능), 24–32로 보고하는 논문은 raw 규약이다. 실제로 문헌의 BiLSTM(raw 규약) FD002/FD004 RMSE 29.67/31.84는 우리의 raw 수치 27.47/27.90과 같은 대역이다. **본 보고서의 cap125 수치가 문헌 주류(cap 규약)와 비교 가능한 값이며, 아래 표는 그 기준으로 정리했다.**

13.2 비교표

Table 16: 문헌 대비 test RMSE (cap 규약 기준). PHM08 score는 괄호. “—”는 미보고.

방법 (연도)	FD001	FD002	FD003	FD004
Deep LSTM, Zheng et al. (2017)	16.14 (338)	—	16.18 (852)	—
DCNN, Li et al. (2018)	12.61 (274)	—	12.64 (284)	—
CNN-LSTM-Attention (2024)	15.98	14.45	13.91	16.64
BiLSTM baseline (raw 규약)	17.60	29.67	17.62	31.84
비교 연구 (2026): Ridge	16.63 (470)	—	17.98 (623)	—
비교 연구 (2026): CNN	16.97 (365)	—	15.68 (648)	—
비교 연구 (2026): 1-layer LSTM	14.93 (411)	—	14.20 (409)	—
비교 연구 (2026): XGBoost	—	—	13.36 (397)	—
본 프로젝트: LightGBM (통합, 무튜닝)	13.74 (378)	14.55 (964)	14.21 (408)	16.26 (1352)
동일 모델, raw 규약 병기	14.98	27.47	15.65	27.90
본 프로젝트: 최종 혼합 (LGBM×LSTM-C)	13.13	13.51	14.13	14.65

(우리 PHM08도 문헌 규약에 맞춰 정답 cap125로 재계산한 값이다. raw 정답 기준은 §7 표 6 참조.)

13.3 위치 판정

- **FD001 13.74** — 클래식 LSTM(16.14)·CNN(16.97)·Ridge(16.63)를 앞서고, 딥러닝 강세 구간(DCNN 12.61, 최신 attention 계열 ≈ 11 –13)에 1 내외로 근접. 무튜닝 GBDT로서 준수한 위치.
- **FD002 14.55 / FD004 16.26** — 다중조건 서브셋에서 최신 딥러닝(CNN-LSTM-Attention 14.45/16.64)과 동급. 조건 정규화+rolling+통합 학습이 다중조건 난이도를 흡수했음을 시사.
- **FD003 14.21 (score 408)** — RMSE는 DCNN(12.64)·XGBoost(13.36)에 뒤지나, score는 Zheng LSTM(852)의 절반 이하.

- 요약: 튜닝 없는 단일 LightGBM으로 클래식 딥러닝(2017–2018 LSTM/CNN)을 상회하고 최신 모델과 견주는 수준. 남은 격차($\approx 1-2$ RMSE)는 튜닝·clip 100·앙상블·LSTM 병행의 몫이다.

13.4 주의 — 비교 불가 판정 사례

일부 문헌은 표준 프로토콜(엔진별 마지막 시점 1회 예측)이 아닌 방식으로 훨씬 낮은 수치를 보고한다. 예: GBDT 앙상블로 FD001 RMSE 6.62를 보고한 연구(Özcan 2025 — 본 프로젝트 README 참고문헌), RF/LGBM으로 FD003 7.95를 보고한 연구. 이런 수치는 test 궤적의 전체 행에 대한 평가나 무작위 행 분할(엔진 미분리)일 가능성이 높다 — 후자는 우리 EDA/전처리가 차단한 바로 그 누수다. 우리의 valid *row-level* RMSE(15.21)와 test *engine-level* RMSE(15.02)가 다른 종류의 수치이듯, 프로토콜이 명시되지 않은 표와의 직접 비교는 피한다.

14 결론과 다음 단계

확정된 것. 전처리 기여의 3중 입증에 완성되었다: (i) GBDT 모델 내 ablation — 특징 제거 시 +2.6 (A2–A4), 조건 지시자 무기여 (A0); (ii) 하이퍼파라미터 표면 평탄 — 24 trial -0.04 , 특징 레버의 $1/25$; (iii) **LSTM 입력 사다리** — 같은 모델에서 전처리만으로 test $16.30 \rightarrow 14.31$, 조건 ”정보”가 아니라 ”제거”가 핵심. 통합 구성 (A6)·주 모델 확정, 그리고 EDA 루프 두 회차(v2·v3)로 최종 test **10.90**(v3 혼합, 4개 서브셋 10.5–11.0 균형) 도달 — 매 단계 적대 검증 통과, 누수 신호 없음. fleet 예측(v3 혼합 모델) 707행을 04로 인계.

다음 단계.

1. 04 스케줄링 — fleet_rul_predictions_unified.csv로 마감 변환 $\rightarrow$ EDF/greedy/SA 비교 (src/pipeline.py 재사용). 분위수 RUL(P10)을 안전마진 s_i 의 원칙적 입력으로 검토.
2. 전처리 v2(선택) — 보완 EDA로 검증된 후보: 자기-기준선 정규화(초기 오프셋 = 열화량의 $\sim 20\%$), onset·누적손상 특징, s9–s14 결합 출현(초기 corr 0.09 $\rightarrow$ 말기 0.63) 지표. 운전 이력 특징은 보완 EDA에서 기각(노출 분산 $\pm 2\%$).
3. A5 후속(clip 100 재검), A8(선형+pruning/PCA)은 future work.

재현. notebooks/03_rul_model.ipynb (seed 42, early stopping 200). 근거. preprocessing_report.tex(입력 데이터·검증 체계), eda_report.tex(EDA 최종본).

문헌 비교 출처 (§9). Zheng et al. 2017 수치·비교 연구 2026: [arXiv:2604.27234](#); Li et al. 2018 DCNN 수치: [MDPI Symmetry 13\(10\):1861](#) 비교표; CNN-LSTM-Attention: [IJCIS 2024](#); BiLSTM(raw 규약)·Bi-cLSTM: [arXiv:2603.00745](#); cap 125 관행: [arXiv:2605.02507](#); Özcan 2025(프로토콜 주의): [Sci. Rep. 15:39795](#); RF/LGBM 사례(프로토콜 주의): [JFAP 2024](#).